



風速之時間序列預測

第二組

12173208 李庭妤


12173234 陳妍蓁

12173241 陳虹璇



摘要

本研究旨在結合時間序列特徵與氣象數據預測風速，以協助綠能調度與防災。研究採用 Kaggle 1961至1978年的歷史氣象數據，經資料清理並建立時間落後特徵後，發現風速具備顯著的短期時間依賴性。相關分析證實，「前一天風速」為預測當日風速最具解釋力的變數，而氣溫與降雨等外部因素影響甚微。最終建構的線性迴歸模型約能解釋 39.7% 的風速變異，該模型能大致反映風速的整體變化趨勢，但對於極端高風速事件仍會出現低估的現象。



前言

在綠能崛起的背景下，風能極具發展潛力，但其高度不穩定性使「精準預測」成為能源調度與防災預警的重大挑戰。事實上，風速變化並非隨機，而是具有顯著的時間延遲（Lag）與氣象連動效應。近年文獻指出，結合時間序列特徵與機器學習模型，能有效捕捉風速的時間依賴關係並提升預測準確度（Anonymous et al., 2023）。此外，學界比較多種機器學習模型後發現，極端梯度提升演算法（XGBoost）能良好地處理氣象資料的非線性波動（Cai et al., 2020；Rakshit & Sengupta, 2024）。基於此，本研究運用 Kaggle 歷史氣象數據建立時間落後特徵，結合機器學習方法，驗證過去的風速規律與氣象因素（如溫濕度）是否能有效預測未來的風速變化。

研究問題與核心假說

- 實務應用價值：氣象預測分析、綠能發電管理、極端氣候交通安全。

- 核心研究問題 (Research Questions)

1. RQ1 (特性探討)：風速是否具備顯著的「時間序列特性」(如趨勢或波動)？




2. RQ2 (歷史預測)：過去的風速數據 (Lag 特徵) 能否有效預測未來風速？

3. RQ3 (外部影響)：氣溫與降雨等氣象因素，對風速變化的影響程度為何？



核心假說 (Hypothesis)

風速並非完全隨機，而是具有時間序列特性；其未來變化可由「過去的風速規律」與「當下的氣象因素」共同解釋與預測。



資料說明


資料集概述 (Dataset Overview)

- 來源：Kaggle：Wind Speed Prediction Dataset
- 區間與規模：1961 - 1978 年，共 6,574 筆 歷史數據
- 紀錄頻率：每日 (Daily Data)


主要變數說明

變數類型	欄位名稱	說明	扮演角色
目標變數 (Y)	WIND	每日風速	模型預測的最終目標
外部解釋變數 (X)	RAIN	降雨量	捕捉外部氣候條件干擾
	T.MAX / T.MIN	最高溫 / 最低溫	測試溫度變化對風速之影響
時間序列特徵 (Lag)	WIND_lag1	前一天風速	捕捉短期時間依賴
	WIND_lag7	前一週風速	捕捉週期性變化規律

分析方法



分析流程



資料前處理

1. 缺失值檢查與填補處理

缺失值統計：

```
DATE      0
WIND      0
IND       0
RAIN      0
IND. 1    61
T. MAX    621
IND. 2    61
T. MIN    674
T. MIN. G 360
dtype: int64
```

處理方式：
以欄位**平均值**填補

2. 欄位清理與特徵篩選

- **時間軸校正**：將 DATE 欄位轉換為標準 Datetime 格式，並依時間進行**升冪排序**，確保時序關係正確。
- **干擾欄位移除**：刪除 IND、IND.1、IND.2。
 - 移除原因：
 - 該指標**未明確定義**，缺乏業務解釋性($|r| < 0.08$)。
 - 分布呈現**高度偏態**，對風速預測貢獻有限，移除可降低模型噪音、提升穩定性。

	WIND	欄位名稱	最常出現的值	該值出現次數	資料總數	集中度佔比
IND	-0.038578	IND	0.0	5893	6574	89.64%
IND.1	0.070512	IND.1	0.0	5912	6574	89.93%
IND.2	0.047860	IND.2	0.0	5352	6574	81.41%
dtype: float64						

資料前處理

3. 特徵工程 (Feature Engineering)

時間特徵與落後特徵 (Lag Features) 建立：

- 時間特徵提取：由 DATE 衍生出 month、day、dayofweek，以利後續分析，藉此捕捉季節性變動與週間（平日/週末）差異。
- 落後特徵 (Lag Features)：
 - WIND_lag1：前 1 天的風速值（捕捉昨日風速對今日的短期依賴）。
 - WIND_lag7：前 7 天的風速值（捕捉每週的週期性變化趨勢）。

***邊界缺失：建立落後特徵後，前 7 筆資料會因「缺乏歷史紀錄」產生 NaN。處理方式 >> 直接刪除這 7 筆不完整的邊界資料 (dropna())，確保模型輸入完整性。**



	DATE	WIND	RAIN	T.MAX	T.MIN	T.MIN.G	month	day	dayofweek	WIND_lag1	WIND_lag7
0	1961-01-08	14.29	0.0	6.6	3.1	0.000000	1	8	6	9.17	13.67
1	1961-01-09	8.04	8.3	6.8	2.4	-0.800000	1	9	0	14.29	11.50
2	1961-01-10	11.42	0.0	6.5	3.0	0.500000	1	10	1	8.04	11.25
3	1961-01-11	7.54	0.5	10.0	-3.1	-7.700000	1	11	2	11.42	8.63
4	1961-01-12	15.54	6.0	12.2	-3.3	2.736547	1	12	3	7.54	11.92




WIND 時序圖



從 WIND 時序圖可觀察到，風速在研究期間呈現**明顯的每日波動**，部分時間點出現較高風速峰值，但整體未呈現明確的長期上升或下降趨勢。由於原始資料波動較大，因此需要進一步透過移動平均觀察較平滑的短期變化。



7日移動平均圖 ✕




✕

7日移動平均圖可降低單日風速劇烈波動造成的干擾，使短期變化趨勢更容易觀察。從圖中可看出，WIND 在不同期間仍存在高低起伏，但整體並未呈現明確單方向變動。此結果顯示風速具有短期波動特性，適合進一步透過 lag 變數分析其時間依賴性。



WIND_LAG1 VS WIND 散佈圖 ✕



WIND_lag1 與 WIND 的散佈圖呈現明顯正向趨勢，表示前一天風速較高時，當天風速也傾向較高。此結果顯示 WIND 具有一定程度的時間依賴性。然而，散佈點仍相當分散，代表前一天風速雖然具有解釋力，但仍無法完全解釋當天風速變化。



相關係數表



WIND VS WIND_LAG1 : 0.587

相關性最高與最重要的變數

WIND_LAG1 VS T.MAX : -0.265

前一天風速與最高溫之間呈現弱負相關的關係

	WIND	WIND_lag1	WIND_lag7	RAIN	T.MAX	T.MIN
WIND	1	0.587	0.165	0.121	-0.23	-0.088
WIND_lag1	0.587	1	0.172	0.064	-0.265	-0.12
WIND_lag7	0.165	0.172	1	0	-0.244	-0.217
RAIN	0.121	0.064	0	1	-0.041	0.011
T.MAX	-0.23	-0.265	-0.244	-0.041	1	0.786
T.MIN	-0.088	-0.12	-0.217	0.011	0.786	1

T.MAX VS T.MIN : 0.786

最高溫和最低溫高度正相關

分析結果

WIND VS WIND_LAG1 : 0.587

✕

WIND_lag1 是目前與 WIND 關聯最明顯的變數(中度正相關)，顯示風速具有短期延續性

WIND VS WIND_LAG7 : 0.165

WIND_lag7 與 WIND 僅呈現弱正相關，表示一週前風速對當天風速的線性關聯較低

WIND VS RAIN : 0.121

降雨量和風速兩者間僅有很弱的正相關，但非常弱

WIND VS T.MAX : -0.230

WIND VS T.MIN : -0.088

T.MAX 與 WIND 呈現弱負相關

幾乎沒有明顯的線性關係


✕

假說驗證&相關係數熱圖



RQ1: 風速是否具有時間序列特性 (如趨勢或波動)
支持，因為 WIND_lag1 和 WIND 相關係數 0.587

RQ2: 過去風速 (LAG) 是否能預測未來風速？
支持，尤其是 WIND_lag1


RQ3: 氣溫與降雨是否會影響風速變化？
較弱支持，因為 RAIN、T.MAX、T.MIN 相關程度偏低



Time Series Feature Analysis (ACF / PACF)



ACF 與 PACF 顯示風速具有明顯短期自相關性
支持使用 WIND_lag1 與 WIND_lag7 作為預測特徵



Linear Regression Model

以多個氣象特徵預測風速 (WIND)，並透過訓練與測試資料評估模型表現

Model Structure

Target Variable (Y)

WIND

Predictor Variables (X)

WIND_lag1
WIND_lag7
RAIN
T.MAX
T.MIN

Data Split

Train Set (80%)
5,253 筆資料

Test Set (20%)
1,314 筆資料

Time Period

Train Period
1961/01/08 ~ 1975/05/27


Test Period
1975/05/28 ~ 1978/12/31

Modeling Process




Data

氣象資料與風速整合後
進行建模



Train / Test Split

依時間順序切分
80% 訓練 / 20% 測試



Linear Regression

建立線性迴歸模型
進行參數估計



Prediction

以測試資料進行預測
取得預測風速



Evaluation


透過 MAE、RMSE
、 R^2 評估模型表現

Model Evaluation

Metric	Value
MAE	3.017
RMSE	3.822
R ²	0.397

模型可解釋約 39.7% 的風速變異
能反映部分風速變化趨勢

Residual Plot



殘差圍繞 0 隨機分布
顯示模型未出現明顯系統性偏誤

Coefficient Analysis

Feature	Coefficient
WIND_lag1	0.542
WIND_lag7	0.059
RAIN	0.1
T.MAX	-0.158
T.MIN	0.118

Key Findings

- WIND_lag1 = 0.542
為模型中最重要的預測變數
- 與 Correlation ($r=0.587$)
及 ACF/PACF 結果一致
- 顯示前一天風速具有明顯預測能力
- WIND_lag7、RAIN、T.MAX
影響相對較弱


與 Correlation Analysis 結果一致
WIND_lag1 為最具解釋力之預測變數

Actual vs Predicted

模型預測結果大致能跟隨實際風速變化趨勢，但在極端高風速事件發生時
=> 預測值於高風速期間仍存在低估現象(Underestimation)



Actual WIND vs Predicted WIND - Test Set



Conclusion

Key Findings

- 風速具有明顯時間依賴性
- WIND_lag1 為最重要預測變數
- 模型可解釋 39.7% 的風速變異
- 極端高風速事件仍存在低估現象

Future Work

- 加入濕度、氣壓等氣象變數
- 嘗試 XGBoost 等非線性模型
- 改善極端高風速事件預測能力



參考文獻

時間序列與機器學習模型的比較




Rakshit, S., & Sengupta, A. R. (2024). Comparison of Machine Learning and Deep Learning Models Performance in predicting wind energy. EAI Endorsed Transactions.

使用 XGBoost 預測風速

Cai, R., et al. (2020). Wind Speed Forecasting Based on Extreme Gradient Boosting. IEEE Access.

時間特徵與機器學習之結合

Anonymous, et al. (2023). A Comparative Analysis of Time Series and Machine Learning Models for Wind Speed Prediction. IEEE Conference Publication.



Thank you

